

CKDデータ分析

慢性腎臓病のリスク因子と若年CKDの特徴を探索する統計解析

UCI Chronic Kidney Disease Datasetを用い、前処理から仮説検証・ロジスティック回帰・施策提案までを一連で実施。

[Python](#) / [pandas](#) / [scikit-learn](#) / [statsmodels](#)

Portfolio Project Overview

1. 分析目的とデータ

「誰に介入すべきか」をデータから考える

分析テーマ

CKDの重症化リスク因子を特定し、早期発見・予防介入につながる示唆を導出する。

データ概要

UCI Chronic Kidney Disease Dataset
約400例 / 24特徴量 + class

データ上の主な課題

欠損値が多く、数値・カテゴリ変数が混在

表記ゆれ・空白・異常値などのデータ品質問題

医療データ特有の非正規性と比較的小さいサンプル数

加工済みと推測される別ファイルに依存せず、生データから前処理を再現

2. 前処理と仮説設計

分析の再現性と臨床的な問いを両立



検証した3つの仮説

仮説① 加齢の影響：年齢はCKDと関連するか。他因子調整後も独立した影響が残るか

仮説② 糖尿病 vs 高血圧：どちらがCKDと強く関連するか。年齢との交互作用はあるか

仮説③ 若年CKDの特徴：40歳未満でCKD群と非CKD群を分ける特徴は何か

3. 主要な分析結果

生活習慣病とCKDの関連を定量化

高血圧 (htn)

OR $\approx$ 2.8

CKDと強く関連

糖尿病 (dm)

OR $\approx$ 2.5

CKDと強く関連

年齢

OR $\approx$ 0.91

単独関連はあるが、調整後の独立影響は弱い

解釈

糖尿病と高血圧はいずれもCKDの主要リスク因子で、影響度はほぼ同等

age $\times$ htn、age $\times$ dm の交互作用は有意 $\rightarrow$ 加齢とともに生活習慣病の影響が増強する可能性

年齢そのものより、腎機能指標や併存疾患を介した間接的な影響を示唆

4. 若年CKDの特徴

40歳未満では生活習慣病以外の特徴が目立つ

CKD群で差がみられた特徴

クレアチニン ↑
ヘモグロビン ↓
ヘマトクリット ↓
赤血球数 ↓
アルブミン尿 ↑
比重異常
浮腫・食欲低下

差が明確でなかった項目

糖尿病 (dm)
高血圧 (htn)

若年CKDでは、生活習慣病よりも腎機能低下・貧血・全身状態悪化を捉える指標が重要な可能性。

示唆：若年層では「生活習慣病の有無」だけでは拾いにくいCKDが存在する可能性

5. 分析から導いた施策提案

リスク層に応じて介入方法を変える

① 生活習慣病の包括管理

対象

糖尿病・高血圧患者
特に中高年層

施策

両疾患を同時に管理
定期的なCr・尿検査

② 高リスク患者の早期検知

対象

医療機関・保険者

施策

予測モデルでリスクスコア化
閾値運用で見逃しを抑制

③ 若年層スクリーニング強化

対象

40歳未満

施策

貧血指標＋尿検査
従来健診で拾えないリスクを補完

6. 限界と今後の改善

探索結果を実運用につなげるために

今回の限界

- サンプル数が約400例と小さい
- 横断データのため因果関係は断定できない
- 欠損値補完によるバイアスの可能性
- 外部データでの検証を未実施

次の改善

- 交差検証と校正評価の追加
- Recall重視の閾値最適化
- 外部検証データで再現性確認
- 臨床的な意思決定支援を意識した説明可能性の強化

重要：本分析は探索的解析であり、診断・治療判断を目的としたものではありません。

7. まとめ

データ分析 → リスク解釈 → 施策提案まで

CKDは単一因子ではなく、複合的な要因で発症・重症化する。

糖尿病と高血圧はいずれも重要なCKDリスク因子

加齢に伴い生活習慣病の影響が強まる可能性

若年CKDでは腎機能・貧血・尿所見など別の特徴が重要

年齢・疾患背景に応じたリスク層別化と早期介入が必要

分析の価値：統計結果を出すだけでなく、「誰に・何をするか」まで落とし込む